

# Template rapport technique – Assistant intelligent de recommandation d'événements culturels


## 1. Objectifs du projet

- **Contexte** : mission pour Puls-Events, plateforme de recommandations culturelles. Besoin d'un chatbot qui répond aux questions des utilisateurs sur les événements à venir.
- **Problématique** : un LLM seul invente des événements et ne connaît pas le catalogue réel. Le RAG branche le LLM sur les vraies données, ce qui donne des réponses fiables et à jour.
- **Objectif du POC** : prouver la faisabilité technique (LangChain + Mistral + FAISS), la valeur métier (réponses utiles), la performance (mesurée avec Ragas)
- **Périmètre** :
  - Zone : Nouvelle-Aquitaine
  - Période : événements récents, 1 an d'historique (filtre sur la date de début)
  - Données : événements publics OpenAgenda (via le portail Opendatasoft)
  - Les événements annulés ou complets sont gardés, c'est au LLM de mentionner le statut.

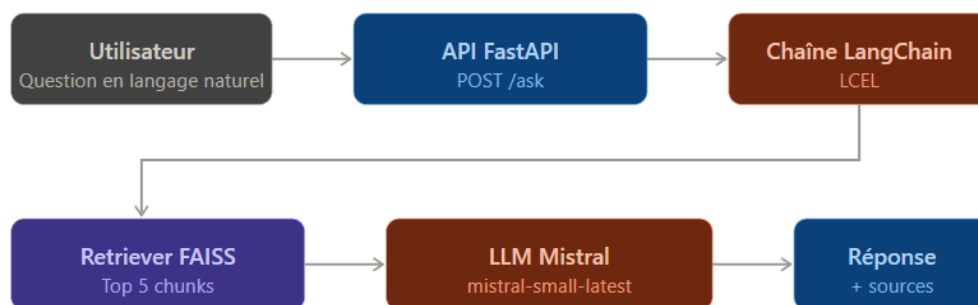
## 2. Architecture du système

- **Schéma global** (schéma UML) :

#### Phase offline : ingestion et indexation



#### Phase online : service API



Index restructurable à la demande via POST /rebuild (protégé)

- Étapes :
  1. Données : API OpenAgenda (Opendatasoft), événements bruts
  2. Prétraitement : nettoyage et structuration, puis documents
  3. Vectorisation : embeddings Mistral, puis index FAISS
  4. RAG : recherche FAISS + génération Mistral, orchestrés par LangChain
  5. Exposition : API FastAPI (/ask, /rebuild, /health)
- Technologies utilisées :
  - Récupération des données : requests + API Opendatasoft
  - Nettoyage : pandas / Python

- Embeddings : mistral-embed (1024 dimensions)
- Base vectorielle : faiss-cpu (recherche par similarité)
- Orchestration : LangChain (relie recherche et LLM)
- Génération : mistral-small-latest
- API : FastAPI + Uvicorn
- Évaluation : Ragas
- Conteneurisation : Docker + Compose

### 3. Préparation et vectorisation des données

- **Source** : dataset evenements-publics-openagenda via l'API Explore d'Opendatasoft.
  - Filtres : région = Nouvelle-Aquitaine et date de début sur les 365 derniers jours
  - Tri du plus récent au plus ancien, pagination par 100, maximum 2000 événements
- **Nettoyage** (preprocessing.py) :
  - suppression des balises HTML et des espaces multiples dans les descriptions
  - parsing des champs JSON pour garder le label français lisible (statut, modalité)
  - sélection des champs utiles uniquement
  - validation : on garde l'événement seulement s'il a un titre, une description et une date
  - déduplication par identifiant (uid)
- **Chiffres** :
  - Événements bruts récupérés : 2000
  - Après nettoyage (filtres + validation + déduplication) : 2000
  - Distribution par état : Programmé 1996, Complet 3, Annulé 1
  - Top départements : Gironde 752, Charente-Maritime 188, Vienne 187, Dordogne 170, Haute-Vienne 130
- **Chunking** (chunking.py) :
  - outil : RecursiveCharacterTextSplitter

- taille : 1000 caractères, chevauchement 200
- raison : éviter des textes trop longs pour l'embedding et garder un contexte cohérent. La plupart des événements tiennent en un seul chunk
- **Embedding :**
  - modèle : mistral-embed (1024 dimensions)
  - les chunks sont envoyés par lots (géré automatiquement par le client Mistral)

## 4. Choix du modèle NLP

- **Modèle de génération :** mistral-small-latest (température 0.3).
- **Pourquoi ce modèle :**
  - imposé par la mission (Mistral) et intégration native avec LangChain
  - bon rapport qualité / coût
  - température basse (0.3) pour des réponses factuelles et peu d'invention
- **Prompting (prompt.py) :** prompt système qui cadre l'assistant
  - répondre uniquement à partir des événements fournis
  - ne pas inventer ; dire clairement si aucun événement ne correspond
  - répondre en français avec le titre, la date et le lieu
- **Limites du modèle :**
  - dépend de la qualité de la recherche (si le bon événement n'est pas retrouvé, il ne peut pas répondre)
  - peut mal interpréter certaines requêtes subjectives

## 5. Construction de la base vectorielle

- **FAISS :** index créé avec FAISS.from\_documents (index plat, similarité L2 par défaut).
- **Persistance :**

- méthode : `save_local()` dans le dossier `data/index/`
  - format : deux fichiers, `index.faiss` (vecteurs) et `index.pkl` (textes et métadonnées)
  - rechargement : `load_local()`
- **Métadonnées conservées par document (`event_to_document.py`) :**
    - identité : uid, titre, url
    - dates : date de début, date de fin, plage de dates lisible
    - lieu : ville, département, région, code postal
    - pratique : statut, modalité, âges min/max, accessibilité, image, lien en ligne
- **Chiffres :**
    - Documents LangChain créés : 2000
    - Chunks indexés : 3002 (moyenne 1.5 chunk par événement)
    - Modèle d'embeddings : mistral-embed (1024 dimensions)

## 6. API et endpoints exposés

- **Framework** : FastAPI + Uvicorn. Documentation interactive Swagger sur `/docs`.
- **Endpoints** :
  - **GET /health** : vérifier que l'API répond
  - **POST /ask** : question, puis réponse + sources
  - **POST /rebuild** : recharger les données et reconstruire l'index (protégé par une clé)

- **Format de la requête /ask** : `{"question": "..."}`
- **Format de la réponse /ask** : `{"answer": "...", "sources": [{uid, title, city, url}]}`

- **Exemple d'appel** :

```
curl -X POST http://localhost:8000/ask -H "Content-Type: application/json" -d '{"question": "Quels concerts de jazz a Bordeaux ?"}'
```

- **Performance** : l'index est chargé une seule fois au démarrage

- **Gestion des erreurs :**
  - question vide : 422
  - index non construit : 503
  - mauvaise clé sur /rebuild : 401
  - erreur de génération : 500
- **Tests :** tests automatiques de l'API dans tests/test\_api.py (santé, question valide, question vide, protection de /rebuild).

## 7. Évaluation du système

- **Jeu de test annoté (data/eval/questions.jsonl) :**
  - 10 questions / réponses de référence
  - annotation manuelle, à partir des vraies données indexées (cas variés : jazz, enfants, ville hors zone, gratuit, science, etc.)
- **Métriques (Ragas, juge = mistral-small) :**
  - **Faithfulness** : la réponse est-elle bien appuyée sur le contexte ?
  - **Answer relevancy** : la réponse colle-t-elle à la question ?
  - **Context precision** : les documents retrouvés sont-ils pertinents ?
- **Résultats obtenus :**
  - **Faithfulness** : 0.611
  - **Answer relevancy** : 0.830
  - **Context precision** : 0.702
- **Lecture** : le système répond bien aux questions (relevancy élevée) et retrouve des documents plutôt pertinents (precision correcte). Le score de faithfulness plus bas s'explique surtout par les questions transversales, où le modèle synthétise au lieu de citer des événements précis.
- **Analyse qualitative :**

### Bonne réponse - question hors périmètre bien refusée

Question : "Y a-t-il des concerts à Paris ?"

Réponse : "Il n'y a aucun concert prévu à Paris parmi les événements disponibles. Les concerts proposés ont lieu en Nouvelle-Aquitaine."

Faithfulness : 1.0

*Le système identifie correctement que la question sort du périmètre et refuse explicitement, sans inventer d'événements à Paris. Il n'hallucine pas.*

### **Réponse faible - question transversale, score bas**

Question : "Quels événements gratuits sont disponibles ?"

Réponse (extrait) : "Plusieurs événements gratuits sont proposés, comme des concerts en libre accès, des conférences en bibliothèque et des visites de patrimoine, principalement à Bordeaux et dans les villes voisines."

Faithfulness : 0.0

*La réponse synthétise au lieu de citer des événements précis. Cette généralisation est difficile à rattacher à un document unique du contexte, ce qui pénalise la métrique. Le système devrait citer 2-3 événements gratuits, ou dire qu'il n'a pas identifié d'événements gratuits.*

## **8. Recommandations et perspectives**

- **Ce qui fonctionne bien :**
  - réponses fidèles aux données, refus correct quand l'information n'existe pas (ex: concerts à Paris)
  - pipeline reproductible (scripts + Docker)
- **Limites du POC :**
  - volumétrie limitée (max 2000 événements, 1 région)
  - coût et latence dépendants de l'API Mistral
  - jeu d'évaluation calé sur des données à l'instant T (si on relance /rebuild, les réponses de référence peuvent dériver)
- **Améliorations possibles :**
  - élargir la zone et la volumétrie
  - ajouter l'historique de conversation
  - mise en production : index managé, cache, authentification renforcée, CI/CD

## 9. Organisation du dépôt GitHub

- **Arborescence :**

```
puls-events-rag/  
  src/  
    data/      récupération + nettoyage OpenAgenda  
    vectorstore/ documents, chunking, index FAISS  
    rag/       retriever, prompt, generator, chain  
    api/       application FastAPI  
  scripts/     fetch_data, build_index, evaluate_rag  
  tests/       tests unitaires (pytest)  
  data/eval/   jeu de test annoté  
  docs/        rapport + schéma + slides  
  Dockerfile, docker-compose.yml  
  pyproject.toml
```

- **Rôle de chaque dossier :**
  - src/data : télécharge les événements et les nettoie
  - src/vectorstore : transforme en documents, découpe, construit l'index FAISS
  - src/rag : la chaîne question, recherche, réponse
  - src/api : expose en HTTP
  - scripts : commandes pour reconstruire les données, l'index, et lancer l'évaluation
  - tests : valident chaque brique

## 10. Annexes (exemples)

- Extraits du jeu de test annoté
  - {"id": 1, "question": "Quels concerts de jazz à Bordeaux ?", "reference\_answer": "Il y a pas mal d'événements autour du jazz à Bordeaux : les Mardis de la musique à la Bibliothèque Mériadeck qui font une conférence sur les influences klezmer/créoles dans le jazz, et quelques autres concerts. Pour du pur jazz, l'offre est limitée."}



- Prompt utilisé (si spécifique)
  - voir src/rag/[prompt.py](#)
- Extraits de logs ou exemples de réponse JSON

Responses

Curl

```
curl -X 'POST' \
  'http://localhost:8000/ask' \
  -H 'accept: application/json' \
  -H 'Content-Type: application/json' \
  -d '{
    "question": "Quels concerts de jazz a Bordeaux ?"
  }'
```

Request URL

http://localhost:8000/ask

Server response

| Code | Details                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                 |
|------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 200  | <p>Response body</p> <pre>{   "answer": "Voici les concerts de jazz à Bordeaux parmi les événements disponibles :\n\n- **Concert du dimanche**\n  *Dimanche 3 janvier 2027, 11h00*\n  Auditorium de Bordeaux (Gironde)\n  *C\n  lassic jazz avec des arrangements originaux et du swing.*\n\n- **Belmondo X Belmondo**\n  *Mardi 8 décembre 2026, 20h00*\n  Auditorium de Bordeaux (Gironde)\n  *Jazz, pop et musique du monde a\n  vec des thèmes de films.*\n\n- **Shai Maestro**\n  *Samedi 28 novembre 2026, 20h00*\n  Auditorium de Bordeaux (Gironde)\n  *Jazz, pop et musique du monde, centré sur l'esprit du piano.*",   "sources": [     {       "uid": "89767981",       "title": "Concert du dimanche",       "city": "Bordeaux",       "url": "https://openagenda.com/ville-de-bordeaux/events/concert-du-dimanche-9755601"     },     {       "uid": "5483075",       "title": "Belmondo X Belmondo",       "city": "Bordeaux",       "url": "https://openagenda.com/ville-de-bordeaux/events/belmondo-x-belmondo"     },     {       "uid": "58923977",       "title": "Mardis de la musique : Influences klezmer et créole dans la musique jazz et moderne",       "city": "Bordeaux",       "url": "https://openagenda.com/ville-de-bordeaux/events/mardis-de-la-musique-influences-klezmer-et-creole-dans-la-musique-jazz-et-moderne"     },     {       "uid": "80451297",       "title": "Shai Maestro",       "city": "Bordeaux",       "url": "https://openagenda.com/ville-de-bordeaux/events/shai-maestro-8176341"     }   ] }</pre> <p>Response headers</p> <pre>content-length: 1468 content-type: application/json date: Thu, 11 Jun 2026 18:06:32 GMT server: uvicorn</pre> |